MiniJava 编译器

——编译课程项目报告

课　　程：　编译

学 号 1：　15307130416

姓 名 1：　韦霞杰

学 号 2：　15307130312

姓 名 2：　曹　楠

分工说明

姓名	学号	分工内容
曹楠	15307130312	错误类型及错误测试、撰写报告
韦霞杰	15307130416	撰写语法分析文件、撰写报告、课程演示

目录

1. 实验概述

本次实验目的是为 miniJava 语言（BNF、详细定义及样例）构造一个编译器的前端，将输入的 miniJava 语言代码段转化成抽象语法树。使用词法/语法自动生成工具 ANTLR 得到语法/词法分析器，再添加 Java 代码使其输出正确的抽象语法树并完善错误处理功能。本项目注重实现编译器的前端，识别 MiniJava 语言，以抽象语法树为输出，主要包括了词法分析、语法分析、语义分析。其中词法/语法分析主要由词法/语法自动生成工具 ANTLR 完成，语义分析包括了变量声明检查、类型检查等，最后还实现了错误检查。

2. 原理介绍

2.1编译原理

编译是利用编译程序从源语言程序转换成目标语言的一个过程。其主要包括前端和后端两个部分，前端用于将源语言程序翻译成中间表示树(IR 树)，主要包括了词法分析、语法分析、语义分析、栈帧布局等动作，后端用于将中间表示树转译成目标语言代码(常常为汇编语言)，包括了规范化、指令选择、控制流分析、数据流分析、寄存器分配等操作。

词法分析，主要是用于对程序中每一个词的识别，例如 ID, 数字，保留字等。词法分析可以通过正则表达式来表示，用有限状态自动机实现。

语法分析，主要是对程序中每句话语法的判别，通常采用上下文无关文法，利用下推自动机进行实现。

语义分析，则是判断程序的语义正确性，包括了各类变量是否已经定义过、变量类型是否匹配、方法的参数列表是否匹配等等。

通过这几步之后，我们可以得到源程序的一棵抽象语法树。抽象语法树将源代码表示成树的形式，以便于后面的处理

2.2 语言识别工具：ANTLR

ANTLR (ANother Tool for Language Recognition) 是一种语言工具，它提供了一个框架，可以通过包含 Java, C++, 或 C# 动作（action）的语法描述来构造语言识别器，编译器和解释器。Antlr 使用上下文无关文法描述语言。在 Antlr 中通过解析用户自定义的上下文无关文法，自动生成词法分析器 (Lexer)、语法分析器 (Parser) 和树分析器 (Tree Parser)。使用 Anltr 的语法可以定义目标语言的词法记号和语法规则，Antlr 自动生成目标语言的词法分析器和语法分析器；此外，如果在语法规则中指定抽象语法树的规则，在生成语法分析器的同时，Antlr 还能够生成抽象语法树；最终使用树分析器遍历抽象语法树，完成语义分析和中间代码生成。

ANTLR 的文法定义主要分两部分，parser rule 和 lexer rule。区分这两种规则的方式是大小写，小写开头的 rule 是 parser rule，大写开头的则是 lexer rule。匹配规则时，按照从上往下的顺序进行匹配，匹配第一个遇到的合法规则。同时 ANTLR 还有如下优点：

（1）有自己的主页和详细的文档，上手容易。

（2）有相应版本的参考书籍。

（3）文法定义友好，输出方式多样化。

2.3 Minijava 语言

Mini Java 是 Java 语言的子集，它与 Java 相比做了如下精简：

（1）不允许重载。

（2）一个文件中可以申明若干个类，但必须有且只有一个的主类，辅类可以有多个，类不能申明为 public；主类中只能有一个主方法，该方法的签名必须为“public static void main(String[])”，其中 String[]参数不做处理。主方法中只能有一条输出语句：System.out.println(int)，该语句只能输出整型变量值。

（3）只有类，没有接口，有继承关系（单继承）。

（4）类中只能申明变量和方法。

（5）只有四种变量类型：整型（integer）、布尔型（boolean）、数组（array）、

对象；只有一类数组：整型数组（int[]）；变量必须申明为(auto)型。

（6）方法必须为 public，必须有返回值，返回值类型受（5）限制；可以有参数，可以没有，参数数量没有限制，类型受（5）限制

（7）一共有 6 中语句（statement）：代码块（block）、简单赋值语句（assignment statement）、数组赋值语句（array assignment statement）、打印语句（print statement）、if 语句、while 语句。

（8）一共有 9 种表达式（expression）：与（and）、比较（compare）、加（plus）、减（minus）、乘（times）、数组定位（array lookup）、数组长度（array length）、消息传递（message sending，即参数传递）、主表达式（primary expression）；与表达式为“短路与”（&&）；比较只能作小于比较。

（9）主表达式一共有 9 种：整数（Integer）、“真”（true）、“假”（false）、对象、this、初始化（allocation）、数组初始化（array allocation）、非（not）、括号（bracket）。

（10）初始化时只能使用空参数，所以没有“构造器（constructor）”概念。

（11）对标识符（IDENTIFIER）没有作明确定义，在这里规定只能是字母、数字的集合，但必须以字母开头，区分大小写。

（12）对整数（INTEGER_LITERAL）没有作明确定义，在这里规定为无符号整数，32 位（0～4294967295）。

（13）不允许注释。

（14）类变量声明时不能初始化，初始化必须在方法中完成。

（15） 不能定义内部类。

2.4 代码思路

1. 导入必要的 java 工具包
2. 一些辅助语法分析的工具函数，主要功能有：
   (1) 检查某个 ID 是否和关键字重复
   (2) 检查某个变量的类型名是否符合要求
   (3) 检查二元运算符的两个操作数的类型是否符合要求
   (4) 判断某个类名是否已经存在

(5) 判断某个函数是否已经在本类中定义,用于实现函数重载机制

3. 规则语法部分.每个规则可以有动作部分,包含在一对大括号中.且可以带属性声明和参数声明和返回值声明,写在一对中括号里,并用关键字 locals 和 returns 指出.
4. 简单的终结符定义,比如运算符、 变量名和空白等

3. 编写文法文件

本实验的词法分析和语法分析等都编写在 MiniJava.g4 文件中，src 文件夹下其他文件为 ANTLR 自动生成或者是测试使用文件。以下是文法文件的编写思路。

3.1词法分析

语言的词法定义包括文法定义用到的 3 个关键字记号：IF、WHILE 和 RETURN，以及其他 4 个记号：变量 ID、数字 NUMBER、换行符 NEWLINE 和空白字符 WS。其中换行符 NEWLINE 和空白字符 WS 不需要作为词法记号向语法分析器传递，使用 skip() 方法将其跳过。

ABTLR 不支持左递归文法。如果定义了非 LL 文法，必须对其改写。在 LL 文法识别器中，算符的优先级要通过文法的嵌套定义来体现。优先级低的算符要优先声明，相同优先级的算符可以在同一个规则中描述。比如加减运算的优先级比乘除运算的优先级低，加减法要先于乘除法定义。

3.2语法分析

整个语言由若干函数定义组成。每个函数定义包括函数名、参数列表和函数体。函数体由若干语句构成，包括返回语句、条件语句、循环语句、赋值语句和表达式运算语句等。表达式定义了语言支持的若干运算，语言中的运算能力主要由表达式定义来体现。

3.3抽象语法树

抽象语法树是语言的结构化表示形式，它的每个节点代表源程序中的某种构造。抽象语法树往往忽略语言中的某些细节， 比如括号（）。当括号用于表示计算的优先级时，树形结构已经拥有了优先级信息，可以去掉；当括号用于表示分隔符时，比如函数声明和函数调用，分隔符在抽象语法

树中不需要存在，可以去掉。抽象语法树不同于语法分析树，后者代表语法分析器分析的完整过程， 而抽象语法树往往使用最少的信息来表示语言本身的结构。可以在定义文法的同时，使用 Anltr 树构造语法来建立抽象语法树，我们语言中的抽象语法树节点主要有以下几类：

（1） 使用占位符作为根节点建立树节点

（2） 使用算符作为根节点建树节点

（3） 依据语义规则条件的不同，建立不同的树节点

（4） 通过文法规则重写建立树节点，去掉相关的分隔符号

3.4扩展功能

我们对 MiniJava 语言进行了如下扩展：

（1） 类的数据成员和函数成员前面可以加 public、 private、 default、 protected 和 static 关键字来声明成员的存取权限和作用域

（2） 允许函数重载

（3） 各个类的书写顺序没有要求

（4） 增加了 return 语句

（5） 不强制一定有一个类含有主函数

（6） 补充了常见的比较运算符和逻辑运算符

（7） 支持多维数组的声明和元素访问

4. 编译器使用步骤

（1）编写 Minijava.g4 语法文件，在其中加入错误处理的 java 代码

（2）执行 antlr4 命令：antlr4 MiniJava.g4

（3）编译生成的 java 文件，执行命令：javac －cp antlr-4.7.2-complete.jar *.java

（4）添加测试代码 binarysearch.java 到目录下

（5）得到语法分析树，执行命令：grun MiniJava prog -gui binarysearch.java

通过以上步骤既可生成 binarysearch.java 程序的语法分析树，得到下图所示语法分析树。

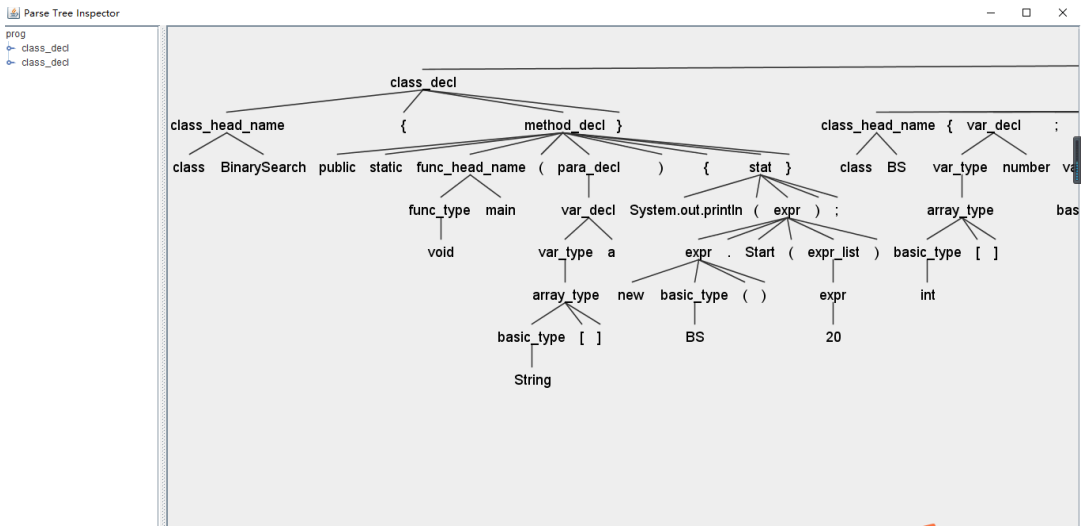

5. 错误处理

我们在语法文件中添加 Java 代码控制行为来检测错误，我们可以处理的错误如下。

（1） 非法字符

文件 error_test1.txt 中有一行非法字符，文件代码如下：

```
########################
class Test{
        void f(){
                return;
        }
}
```

使用 MiniJava 进行语法分析之后结果如下，正确检测到错误。

```
line 1:0 token recognition error at: '#'
line 1:1 token recognition error at: '#'
line 1:2 token recognition error at: '#'
line 1:3 token recognition error at: '#'
line 1:4 token recognition error at: '#'
line 1:5 token recognition error at: '#'
line 1:6 token recognition error at: '#'
line 1:7 token recognition error at: '#'
line 1:8 token recognition error at: '#'
line 1:9 token recognition error at: '#'
line 1:10 token recognition error at: '#'
line 1:11 token recognition error at: '#'
line 1:12 token recognition error at: '#'
line 1:13 token recognition error at: '#'
line 1:14 token recognition error at: '#'
line 1:15 token recognition error at: '#'
line 1:16 token recognition error at: '#'
line 1:17 token recognition error at: '#'
line 1:18 token recognition error at: '#'
line 1:19 token recognition error at: '#'
line 1:20 token recognition error at: '#'
line 1:21 token recognition error at: '#'
line 1:22 token recognition error at: '#'
line 1:23 token recognition error at: '#'
add new class name:Test to class name list
add function:f to class Test success
```

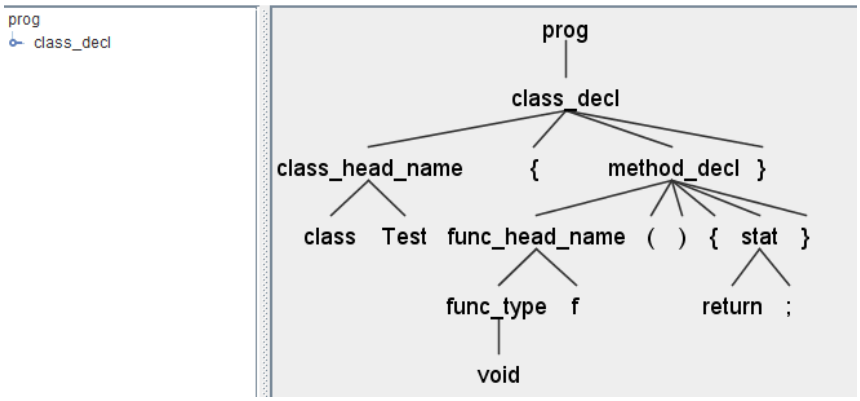

（2） ID 为关键词

文件 error_test2.txt 的代码如下，其中 class 是关键词。

```
class class{
        void f(){
                return;
        }
}
```

使用 MiniJava 进行语法分析之后结果如下，抽象语法树上会有红色标记提示出错。

```
line 1:6 mismatched input 'class' expecting ID
add new par: x in function f successful
add new var: y in function f successful
add function:f to class null success
```

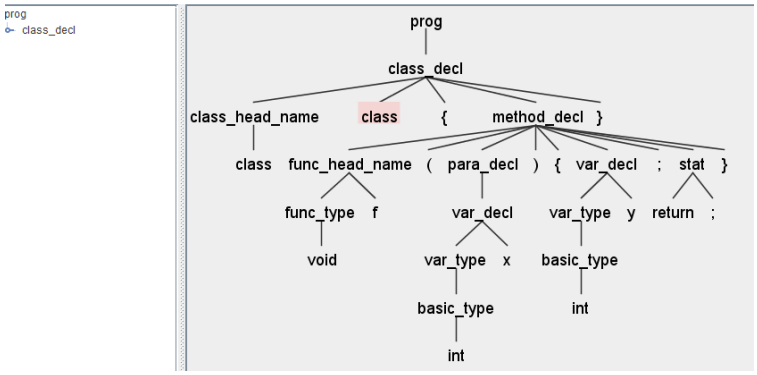

（3） 变量重复定义

文件 error_test3 的代码如下，变量 R 被重复定义。

```
class Test{
        int R;
        boolean R;
}
```

使用 MiniJava 进行语法分析之后结果如下。

```
add new class name:Test to class name list
add new member var: R in class Test successful
var R is refined at line 3:9
```

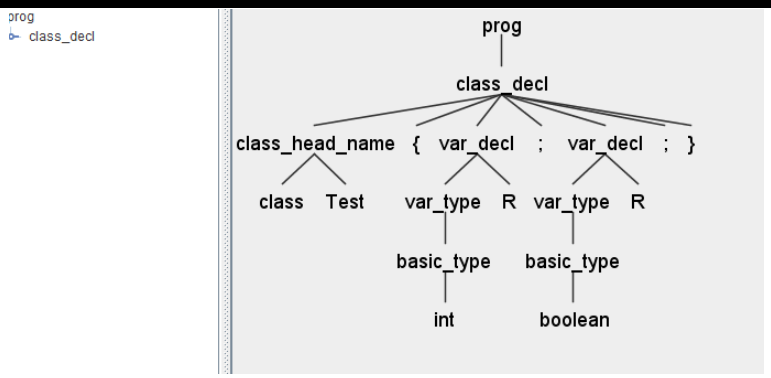

（4） 参数重名

文件 error_test4.txt 的代码如下，其中函数 f()的两个参数同名。

```
class Test{
        int f(int x, int x){ }
}
```

得到结果如下，指出了错误位置和类型。

```
add new class name:Test to class name list
add new par: x in function f successful
para x in functionf is refined at line 2:18
add function:f to class Test success
```

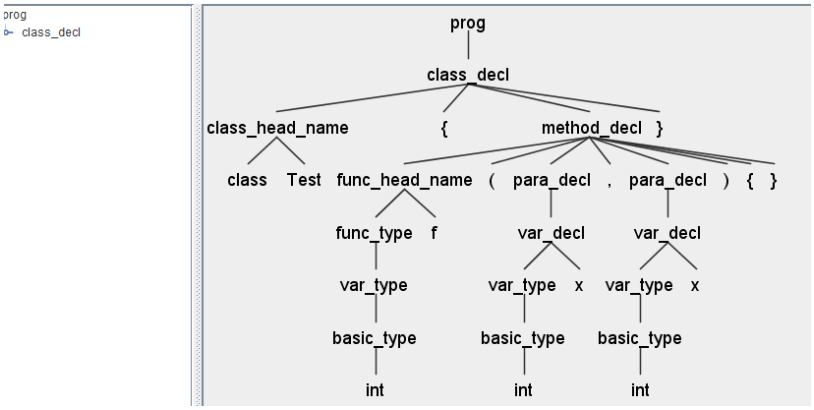

（5） 算术表达式类型错误

文件 error_test5.txt 的代码如下，其中 x 和 y 的类型不能进行加法运算。

```
class Test{
        int f(){
        int x;
        boolean y;
        x=1+y;
        return;
        }
}
```

得到结果如下，指出了错误类型和位置。

```
add new class name:Test to class name list
add new var: x in function f successful
add new var: y in function f successful
type mismatched in arg2 of expression at line 5:4
add function:f to class Test success
```

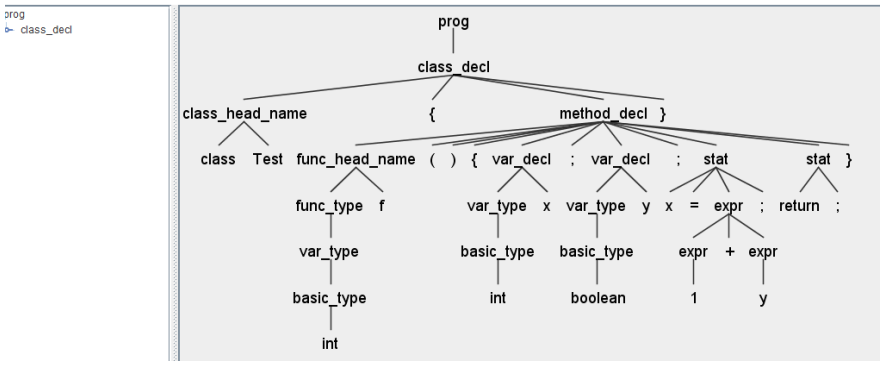

（6） 函数重载错误

文件 error_test6.txt 的代码如下，其中两个函数重载产生了二义性。

```
class Test{
        int f(int x){ }
        int f(int y){ }
}
```

得到结果如下，指出了错误类型和位置。

```
add new class name:Test to class name list
add new par: x in function f successful
add function:f to class Test success
add new par: y in function f successful
overload function:f in class Testfailed at line 3:6
```

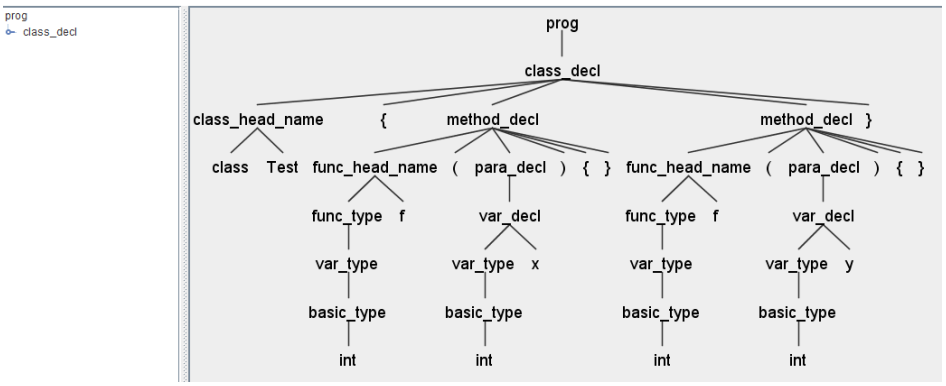

我们还处理了其他的错误，包括类名重复、类变量重名错误、函数内变量重名错误等，因为处理方式和上面的几个类型差不多，所以不再一一截图分析。

6. 分析与感想

通过本次项目实现了对编译器前端的编写，我们加深了对编译原理的理解，了解了编译器实现词法分析、语法分析、语义分析，以及各类错误报告和错误恢复的大致流程。同时我们也深入学习 ANTLR 语法分析器。

整个项目参考了大量 ANTLR Reference 和网络上的实例。我们在其中也遇到了很多问题，比如处理赋值语句时,最开始的规则写法是：

```
stat: ID ASSIGN_OP expr ';'
| ID '[' expr ']' '=' expr ';'
```

测试时在函数里写如下语句:

```
x =2;
```

结果语法分析器总在这里报错.经过思考和调试，最后发现原因是 antlr 是 LL(1)的,每次最多向后读取一个词法元素,而开始的写法右边的两条展开式首部相同,造成 parser 无法预测采用哪个分支。改进之后为如下形式,测试通过，使赋值号的左边即可以是一个简单的变量也可以是一个数组元素。

```
stat: ID (array_index)? ASSIGN_OP expr ';'
array_index:
('[' expr ']')+;
```

在查找变量时，如果在本作用域没找到， 需要继续到父作用域查找。我们开始用的思路是增加一个全局栈，存储遇到的每个规则节点，查找时把每个规则对象依次出栈，在该对象里查找符号。后来通过参考官方文档发现 antlr 中提供了 getParent 函数可以直接访问父对象，使用之后页可以大大减少代码量。